DINOv3-PPP: aktueller Decoder
3×3-Projektionen · Pixel Shuffle · versetzte Attention-Fenster

Transformer-Neck
1152 Channels · 32×32

3×3-Conv: 1152 → 2048 Channels
Pixel Shuffle ×4
128 Channels · 128×128

2 Residual-Attention-Blöcke
128 Channels · 128×128

3×3-Conv: 128 → 1024 Channels
Pixel Shuffle ×4
64 Channels · 512×512

2 Residual-Attention-Blöcke
64 Channels · 512×512

Jeder Residual-Attention-Block
① Zwei 3×3-Convs mit Residualverbindung
② 8×8-Window-Attention mit Residualverbindung
③ MLP mit Residualverbindung

Block 1: normale Fenster
Block 2: um 4 Positionen versetzte Fenster
Keine Verbindung gegenüberliegender BEV-Ränder

3×3-Conv: 64 → 128 Channels
Pixel Shuffle ×2
32 Channels · 1024×1024

2 Residual-Attention-Blöcke
32 Channels · 1024×1024

1×1-Conv: 32 → 3 Channels
Keine abschließende Aktivierung
Ausgabe: (B, 3, 1024, 1024)

Drei rohe Felder
Log-Intensität | RCS roh | Doppler roh

Training: kontinuierliche PPP- und Mark-Losses
Koordinaten jeder Detektion → Vorhersagezelle
Mehrere Detektionen pro Zelle bleiben erhalten

Inferenz: Radar-Punktwolke
Zellmasse = exp(Log-Intensität) / (1024×1024)
Poisson-Sampling pro Zelle
RCS = (RCS roh)³ · Doppler = (Doppler roh)³

Alle Raster decken dieselbe Fläche ab: 100 m × 100 m.
Kein bilineares / Nearest-Neighbor-Upsampling.
Nach der Feldausgabe kein weiteres Resizing.